

Zadanie szkoleniowe

ChatGPT, kontrola halucynacji i analiza jakości danych w Excelu

Cel ćwiczenia: uczestnicy mają samodzielnie zaprojektować prompty do rozwiązywania trzech różnych problemów, sprawdzić, czy odpowiedzi chatbota nie zawierają halucynacji, a następnie wykonać analizę jakości danych na pliku CSV z celowo wprowadzonymi błędami.

Materiały wejściowe	1. Ten dokument z treścią zadania. 2. Plik CSV: kursanci_dane_osobowe_bledy_10000.csv. 3. ChatGPT lub inny chatbot do części promptowej. 4. Excel do części analitycznej.
---------------------	--

Część 1. Trzy problemy do rozwiązania z pomocą ChatGPT

Zadanie ogólne: dla każdego problemu przygotuj własny prompt, uzyskaj odpowiedź od chatbota, a następnie przygotuj prompt kontrolny, który sprawdzi możliwe halucynacje, nadinterpretacje i ukryte założenia.

Dla każdego problemu kursant powinien oddać:

- prompt podstawowy, czyli pierwszą wersję polecenia;
- prompt poprawiony, z rolą, kontekstem, ograniczeniami i oczekiwanym formatem odpowiedzi;
- prompt kontrolny do wykrywania halucynacji;
- krótką ocenę odpowiedzi: co jest pewne, co jest założeniem, co wymaga sprawdzenia;
- wersję końcową odpowiedzi po korekcie.

Problem	Opis sytuacji	Co ma zrobić kursant	Ryzyko halucynacji
Problem 1: wyjaśnienie pojęć	Przełożony prosi o krótkie, zrozumiałe wyjaśnienie: czym jest chatbot, czym jest duży model językowy, czym różni się odpowiedź modelu od wyszukiwarki i dlaczego model może się mylić.	Napisz prompt, który wymusi prosty język, przykłady z pracy biurowej, listę ryzyk oraz krótką checklistę bezpiecznego użycia.	Model może podać zbyt pewne definicje, mieszać pojęcia, wymyślić funkcje narzędzi albo uprościć temat tak mocno, że zgubi sens.
Problem 2: decyzja biznesowa bez danych liczbowych	Firma widzi, że sprzedaż rośnie, ale zysk nie rośnie proporcjonalnie. Wiadomo tylko, że wzrosły rabaty i koszty obsługi klientów. Nie ma jeszcze pełnego pliku danych.	Napisz prompt, który poprosi chatbota o hipotezy, pytania analityczne, potrzebne dane, możliwe wskaźniki i strukturę raportu. Model nie może wymyślać liczb.	Model może wymyślić dane, uznać hipotezy za fakty albo wskazać przyczynę bez dowodów.
Problem 3: wsparcie techniczne analizy danych	Analitik chce sprawdzić jakość tabeli klientów: braki, duplikaty, błędne maile, błędne numery telefonu, błędne daty i niespójności między datą urodzenia a PESEL.	Napisz prompt, który poprosi o plan analizy oraz przykładowe formuły lub pseudokod. Prompt ma wymusić, żeby chatbot pytał o strukturę danych, zamiast zgadywać kolumny.	Model może założyć nieistniejące kolumny, podać formuły niezgodne z polską wersją Excela albo pominąć ograniczenia walidacji PESEL.

Szablon kontroli halucynacji

Pytanie kontrolne	TAK/NIE	Komentarz kursanta
Czy chatbot dodał liczby, fakty lub funkcje, których nie było w poleceniu?		
Czy chatbot rozdzielił fakty, hipotezy i rekomendacje?		

Czy chatbot wskazał, które elementy wymagają sprawdzenia w źródle lub dokumentacji?		
Czy odpowiedź zawiera ukryte założenia?		
Czy odpowiedź jest użyteczna dla osoby nietechnicznej?		
Czy prompt kontrolny poprawił jakość odpowiedzi?		

Część 2. Analiza pliku CSV z błędami w Excelu

Plik wejściowy: kursanci_dane_osobowe_bledy_10000.csv. Plik ma separator średnikowy, kodowanie UTF-8 i 10 000 wierszy danych. Wszystkie dane są fikcyjne.

Kolumna	Opis	Przykładowe problemy do wykrycia
id_klienta	Identyfikator rekordu	duplikaty, braki, nieciągłość numeracji
imie	Imię osoby	braki, spacje, różna wielkość liter
nazwisko	Nazwisko osoby	braki, spacje, różna wielkość liter
email	Adres e-mail	braki, brak @, błędna domena, duplikaty
telefon	Numer telefonu	braki, litery, zła długość, różne formaty zapisu
pesel	Numer PESEL	braki, zła długość, znaki inne niż cyfry, błędna suma kontrolna, duplikaty
data_urodzenia	Data urodzenia	braki, błędny format, data niezgodna z PESEL

Polecenie dla kursantów

1. Zaimportuj plik CSV do Excela. Upewnij się, że separator to średnik, a polskie znaki wyświetlają się poprawnie.
2. Utwórz arkusz „Dane” z oryginalnymi danymi oraz arkusz „Dane_czyste” albo kolumny pomocnicze z oczyszczonymi wartościami.
3. Wykonaj profilowanie danych: liczba wierszy, liczba kolumn, liczba braków w każdej kolumnie, liczba wartości unikalnych, liczba duplikatów.
4. Wykryj błędy jakości danych: puste imiona/nazwiska, błędne lub puste e-maile, błędne lub puste telefony, błędne PESEL, duplikaty PESEL, błędne daty oraz niezgodność daty urodzenia z PESEL.
5. Utwórz arkusz „Bledy” z listą rekordów problematycznych. Przy każdym rekordzie wpisz typ wykrytego problemu.
6. Utwórz arkusz „Wyniki” z tabelą podsumowującą liczbę błędów według kategorii.
7. Dodaj prosty wykres słupkowy: liczba błędów według kategorii.
8. Napisz 5 wniosków i 3 rekomendacje dotyczące czyszczenia danych.
9. Zapisz wynik jako plik XLSX.

Wymagany efekt końcowy: plik Excel

Arkusz	Zawartość
Dane	Zaimportowane dane źródłowe z CSV.
Profilowanie	Podsumowanie kolumn: braki, unikalność, duplikaty, typy problemów.
Bledy	Lista rekordów z błędami oraz kolumna z opisem problemu.
Wyniki	Tabela liczby błędów według kategorii i wykres słupkowy.
Wnioski	Krótki opis jakości danych, rekomendacje i ryzyka interpretacji.

Podpowiedzi formułowe do Excela

Uwaga: formuły mogą wymagać dostosowania do wersji językowej Excela i separatora argumentów. W polskim Excelu zwykle używa się średnika jako separatora argumentów.

Cel	Przykład / kierunek formuły
Braki w kolumnie	=LICZ.PUSTE(B:B)
Usuwanie zbędnych spacji	=USUŃ.ZBĘDNE.ODSTĘPY(B2)
Duplikat emaila	=LICZ.JEŻELI(\$D:\$D;D2)>1
Czy email zawiera @	=CZY.LICZBA(ZNAJDŹ("@";D2))
Czy PESEL ma 11 znaków	=DŁ(F2)=11
Czy data wygląda jak data	=CZY.LICZBA(G2) lub próba konwersji tekstu na datę
Łączenie opisów błędów	=TEKST.ZŁĄCZ lub ręczne kolumny flag błędów

Kryteria oceny

- Poprawność importu i zachowanie polskich znaków.
- Czytelna struktura arkuszy i nazw kolumn.
- Wykrycie głównych klas błędów, a nie tylko braków danych.
- Oddzielenie błędów krytycznych od kosmetycznych.
- Czytelny arkusz „Wyniki” i wykres.
- Umiejętne użycie ChatGPT bez bezkrytycznego przyjmowania odpowiedzi.
- Jawne wskazanie miejsc, gdzie chatbot mógł halucynować.

Pytania końcowe do omówienia na sali

1. Który problem najłatwiej było rozwiązać z pomocą ChatGPT?
2. W którym miejscu chatbot najchętniej dopowiadał coś od siebie?
3. Jakie informacje trzeba było doprecyzować, aby odpowiedź była użyteczna?
4. Które błędy w CSV są krytyczne dla dalszej analizy?
5. Czy Excel wystarczył do profilowania danych, czy przydałby się Python lub Power Query?